


ReLU: $\mathbb{R} \rightarrow \mathbb{R}$

$$\text{ReLU}(x) = \begin{cases} 0; & x < 0 \\ x; & x \geq 0 \end{cases} = \max(0, x).$$



Clasificación:

Última capa #neuronas = # categorías

activation = softmax.

$$\text{Softmax}(x_1, x_2, \dots, x_k)$$

$$= \left(\frac{e^{x_1}}{\sum_{i=1}^k e^{x_i}}, \frac{e^{x_2}}{\sum_{i=1}^k e^{x_i}}, \dots, \frac{e^{x_k}}{\sum_{i=1}^k e^{x_i}} \right)$$

$y_1 \quad y_2 \quad \dots \quad y_k$


$$\Rightarrow \sum_{i=1}^k y_i = 1$$

$$P(x \in C_1)$$

$$P(x \in C_2)$$

$$P(x \in C_k)$$

max




* se clasifica como 2



Regresión:

neuronas = dimensión
del dato a estimar

activación = identidad



$$y \in \mathbb{R}^1$$

$$(x, y) \in \mathbb{R}^2$$

Descenso Gradiente:

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

Queremos hallar $x^* \in \mathbb{R}^n$ que minimiza $f(x)$.

x_0 cualquiera


$$x_{n+1} = x_n - \alpha \nabla f(x_n)$$

x

$W^{(k)}$ = matriz de pesos en la capa k de la red
 $= [w_{ij}^{(k)}]$

fijos

x_1
 \vdots
 x_n




loss function

$$L(y_i) = L(x_i, w_{ij}^{(k)})$$

Backtracking

$$y = \varphi_n \left(\underbrace{W_2}_{w_{ij}^{(2)}} \varphi_1 \left(\underbrace{W_1}_{w_{ij}^{(1)}} x + b_1 \right) + b_2 \right) \dots$$

$$w_{ij}^{(k), n+1} = w_{ij}^{(k), n} - \alpha \nabla_{w_{ij}} L(x_i, w_{ij}^{(k), n})$$



epoch 1

Batches



epoch 2

Batches ó el batch-size :

hasta que el descenso gradiente converge.

algoritmo

α tamaño paso \approx learning rate # epochs